

Síntesis y Clonación de Voz con IA

Caso Práctico: Presentación

Roberto García y Juan Antonio Álvarez

Escuela Politécnica de Cáceres

5 de mayo de 2026

- **Objetivos del proyecto:**

- 1 Evaluar el estado del arte de modelos TTS.
- 2 Comparar su rendimiento y exigencias técnicas.
- 3 Aplicar la tecnología a un caso real de localización (doblaje).

- **Coqui VITS:**

- Arquitectura tradicional *End-to-End*.
- Destaca por su rapidez, pero carece de flexibilidad para clonación rápida.

- **Suno Bark:**

- Modelo generativo basado en *Transformers*.
- Altamente expresivo (risas, dudas, suspiros), pero lento y con tendencia a sufrir "alucinaciones".

- **Coqui XTTS v2:**

- El equilibrio perfecto (Autoregresivo + VQ-VAE).
- Permite clonación exacta de voz y habla en múltiples idiomas.

Modelo	Calidad Visual (MOS)	Velocidad	Hardware Necesario
VITS	Buena (~ 4.0)	Muy Alta	Bajo (CPU)
Bark	Alta, Expresiva (~ 4.3)	Baja	Alto (GPU)
XTTS v2	Excelente, Natural (~ 4.5)	Media	Medio (GPU)

Selección para el Caso Práctico

Se selecciona **XTTS v2** como la herramienta ideal por su capacidad de mantener el timbre de voz original al traducir textos a otros idiomas.

Caso Práctico: Doblaje (Localización)

Objetivo: Traducir y doblar un fragmento de vídeo del inglés al español manteniendo la voz del actor original.

- 1 **Extracción:** Aislamiento del audio original para usarlo como referencia (*speaker wav*).
- 2 **Generación:** Envío del guion en español al modelo XTTS v2 utilizando la voz extraída.
- 3 **Postproducción:** Acoplamiento del nuevo audio generado sobre la pista de vídeo original.