

Síntesis y Clonación de Voz con IA

Memoria del Caso Práctico

Roberto García García Juan Antonio Álvarez Redondo

5 de mayo de 2026

Índice

1. Introducción y Objetivos	3
2. Entorno y Requerimientos	3
3. Evaluación de Modelos TTS	3
3.1. Coqui VITS	3
3.2. Suno Bark	3
3.3. Coqui XTTS v2	4
4. Análisis Comparativo	4
5. Caso Práctico: Localización y Doblaje	4
5.1. Metodología	4
5.2. Resultados	4
6. Conclusiones	5
7. Enlace al repositorio Github	5

1. Introducción y Objetivos

La síntesis de voz neuronal (Text-To-Speech o TTS) ha experimentado avances significativos en los últimos años, pasando de sistemas de concatenación de fragmentos de audio a arquitecturas de aprendizaje profundo capaces de generar habla con alta naturalidad. El presente documento detalla el desarrollo de un caso práctico centrado en la evaluación de modelos TTS modernos y su aplicación en la clonación de voz.

Los objetivos principales de este proyecto son:

1. Comprender los fundamentos de la síntesis de voz neuronal.
2. Comparar el rendimiento de tres modelos actuales (VITS, Bark y XTTS) en términos de calidad perceptual, inteligibilidad y velocidad de inferencia.
3. Aplicar la tecnología de clonación de voz *Zero-Shot* a un caso real de localización (doblaje) de un fragmento de vídeo.

2. Entorno y Requerimientos

Para garantizar la reproducibilidad del proyecto, se ha definido un entorno virtual utilizando Conda. Las dependencias principales incluyen PyTorch (para el procesamiento tensorial en GPU), la librería TTS de Coqui y la librería `transformers` de HuggingFace para la ejecución de modelos como Bark. El código fuente completo y los archivos de audio resultantes se encuentran documentados en el notebook interactivo `demo_sintesis_voz.ipynb`.

3. Evaluación de Modelos TTS

Durante el desarrollo del caso práctico, se ejecutaron y analizaron tres arquitecturas distintas de síntesis de voz:

3.1. Coqui VITS

VITS (Variational Inference with adversarial learning for end-to-end Text-to-Speech) es un modelo *end-to-end* tradicional. Durante las pruebas, destacó por su altísima velocidad de inferencia y baja exigencia de hardware. La inteligibilidad del texto generado es perfecta, aunque la calidad perceptual denota un tono ligeramente robótico y monótono en comparación con modelos más recientes. No permite clonación de voz sin un proceso de *fine-tuning* previo.

3.2. Suno Bark

Bark es un modelo generativo basado en la arquitectura *Transformer*, operando de forma similar a los grandes modelos de lenguaje (LLM) pero en el dominio del audio. En nuestras pruebas, Bark demostró una expresividad superior, siendo capaz de generar efectos no verbales (como pausas, suspiros o risas). Sin embargo, su principal desventaja es el alto coste computacional (requiriendo GPUs potentes) y una tendencia a sufrir “alucinaciones” de audio o pérdida ocasional de inteligibilidad.

3.3. Coqui XTTS v2

XTTS es un modelo avanzado que combina características autorregresivas con VQ-VAE. Este modelo representó el punto de equilibrio óptimo del proyecto. Su característica principal es la capacidad de *Zero-Shot Voice Cloning*, permitiendo clonar el timbre de voz de un hablante utilizando únicamente un archivo de referencia de unos pocos segundos. Además, soporta generación multilingüe, manteniendo el timbre original independientemente del idioma de destino.

4. Análisis Comparativo

A partir de la ejecución empírica en el notebook, se ha elaborado la siguiente matriz comparativa que evalúa las dimensiones clave de cada modelo:

Modelo	Arquitectura	Calidad (MOS est.)	Velocidad	Requisitos Hardware
VITS	Red End-to-End (GAN/Flows)	~ 4.0 - 4.2	Muy Alta	Bajos (Apto para CPU)
Bark	Transformer Generativo	~ 4.3 (Muy expresivo)	Baja	Altos (GPU necesaria)
XTTS v2	Autoregresivo + VQ-VAE	~ 4.5 (Alta naturalidad)	Media	Medios (> 4GB VRAM GPU)

Cuadro 1: Comparativa de modelos TTS analizados en el proyecto.

5. Caso Práctico: Localización y Doblaje

La culminación del proyecto consistió en la aplicación práctica de la síntesis de voz para el doblaje de un fragmento de vídeo, automatizando la localización del idioma inglés al español.

5.1. Metodología

El proceso seguido en el notebook constó de los siguientes pasos:

- **Extracción de referencia:** Se aisló la pista de audio del vídeo original en inglés (`referencia_ingles.wav`) para obtener la “huella dactilar” vocal del hablante.
- **Selección de modelo:** Basado en los resultados de la sección anterior, se seleccionó XTTS v2 por su soporte multilingüe y clonación *Zero-Shot*.
- **Síntesis y Traducción:** Se introdujo el guion traducido al español en el motor de inferencia, pasándole como parámetro el audio de referencia extraído.

5.2. Resultados

El modelo XTTS v2 logró generar el diálogo en español manteniendo el tono, el timbre y las cadencias del hablante original anglosajón. El archivo resultante (`audio_doblado_es.wav`) demuestra la viabilidad técnica de utilizar IA generativa para abaratar y acelerar los procesos de localización en la industria audiovisual, aunque sigue presentando retos menores en la sincronización labial automática (*lip-sync*).

6. Conclusiones

El desarrollo de este caso práctico ha permitido confirmar la rápida evolución de los modelos de voz. Mientras que arquitecturas como VITS siguen siendo útiles para notificaciones o asistentes de voz básicos, la irrupción de modelos generativos como XTTS y Bark abre un nuevo paradigma.

El éxito en el doblaje del caso práctico evidencia el enorme potencial de la clonación de voz, a la vez que subraya la necesidad de abordar sus implicaciones éticas y de seguridad ante la facilidad de generar suplantaciones de identidad (deepfakes de voz) con apenas unos segundos de audio público.

7. Enlace al repositorio Github

<https://github.com/rgarciaee/CasoPracticoSM.git>